

LangSmith를 사용한 평가



1. LangSmith 평가 개념

LangChain의 LangSmith 평가(Evaluation) 개념 설명

LangSmith는 **LangChain** 기반 LLM 애플리케이션의 개발, 디버깅, 모니터링, 평가를 위한 플랫폼이다.

“평가(Evaluation)”는 **RAG 시스템이나 에이전트의 품질을 자동으로 측정**하는 핵심 기능이다.

평가 방식은 크게 **두 가지**가 있다

- (1) **기준 기반 평가**(Criteria-Based Evaluation)
- (2) **기준 없는 비교 평가**(Comparison Evaluation)

1. 기준 기반 평가(Criteria-Based Evaluation)

LLM을 사용하여 모델의 응답을 평가하는 대표적인 방법이다.

개념

- 사람이 미리 정한 기준(criteria)을 바탕으로 LLM이 응답을 점수로 평가한다.
- 예: 정확성(correctness), 간결성, 유용성, 관련성 등

흐름

1. **Dataset**: 입력(question)과 정답(reference)를 LangSmith Dataset에 저장한다.
2. **LLM-as-a-Judge**: 오픈AI 모델 등 LLM이 응답을 판단한다.
3. **LangChain Evaluator**: LangChainStringEvaluator를 사용하여 점수를 계산한다.
4. **LangSmith Dashboard**에서 평가 결과를 시각적으로 확인한다.

장점

- 사람이 직접 채점할 필요가 없다.
- RAG, QA 시스템에서 가장 자주 사용한다.

2. 기준 없는 비교 평가(Comparison Evaluation)

두 개 이상의 모델 또는 프롬프트 버전을 비교하는 평가이다.

개념

- LLM에게 "A 응답과 B 응답 중 어떤 것이 더 좋은가?" 를 물어보는 방식이다.
- A/B 테스트와 유사하다.

사용 시나리오

- 프롬프트 버전 비교
- 모델 버전 비교
- RAG 검색 전략 비교 (ex. MultiQuery vs RAG Fusion)

2. LangSmith 평가 구조

1) Dataset

LangSmith Dataset은 평가에 사용할 데이터를 저장하는 컬렉션이다.

예:

- question: "서울의 봄 날씨는?"
- answer(정답): "봄은 대체로 온화하며 벚꽃이 피는 시기이다."

Dataset은 수동 입력, **CSV** 업로드, **API** 자동 생성 모두 가능하다.

2) Run(실행 기록)

LangSmith는 모든 LLM 호출을 "Run"으로 저장한다.

평가는 Run을 기반으로 진행한다.

예:

- 사용자의 QA 시스템이 질문에 대해 생성한 답변을 "run.outputs['answer']"로 저장
- 평가 시 evaluator가 이 값을 참조한다

3) Evaluator

LangChain이 제공하는 평가 모듈이다.


대표 evaluator

- "qa": 정답과 비교하여 정확성 판단
- "criteria": 기준 기반 판단
- "embedding_distance": 벡터 거리 기반 평가
- "model graded": LLM-as-a-judge 기반 자동 평가

LangChainStringEvaluator는 아래처럼 결과를 입력받는다.

```
python

LangChainStringEvaluator(
    "qa",
    prepare_data=lambda run, example: {
        "input": example.inputs["question"],
        "prediction": run.outputs["answer"],
        "reference": example.outputs["answer"]
    },
)
```

LangSmith 평가 전체 흐름

아래는 일반적인 평가 파이프라인이다.

1. Dataset 생성
 2. QA 시스템 실행 → Run 생성
 3. Evaluator 설정
 4. LangSmith evaluate() 호출
 5. 대시보드에서 결과 시각화 (점수·그래프)
- 

LangSmith에서 확인할 수 있는 주요 지표

LangSmith Dashboard에서는 아래 항목을 볼 수 있다:

(1) Score

- 평가 결과 점수이다.
- 0.0 ~ 1.0 또는 custom metrics 가능

(2) Verdict

- LLM 평가 기준에 따른 판단
- 예: "Correct", "Incorrect", "Partial"

(3) Reasoning

- LLM이 왜 이렇게 평가했는지 이유 제공
- 디버깅에 매우 유용하다

(4) Inputs / Outputs

- 실제 입력 질문
- 모델의 응답
- 정답(reference)

LangSmith 평가의 대표적인 활용 시나리오

1) RAG 품질 평가

- 정답(reference) 대비 정확도
- 검색된 문맥(context)의 적절성
- 사실성(Faithfulness)

2) 프롬프트 엔지니어링

- 프롬프트 버전 비교
- LLM-as-a-judge로 자동 채점

3) 모델 버전 비교

- gpt-4o vs gpt-4o-mini
- Llama3 vs GPT4 등 비교 가능

4) 에이전트 평가

- Tool 사용이 적절했는지
- 응답 품질
- hallucination 여부

왜 LangSmith 평가를 사용하는가?

1) 완전 자동화

- 사람이 수백 개의 질문을 일일이 평가할 필요가 없다
- LLM이 기준에 따라 자동으로 채점한다

2) 대규모 테스트가 가능

- dataset 1,000개도 자동 채점 가능

3) 추적 기능

- 어느 질문에서 문제가 발생했는지 쉽게 찾는다

4) 버전 관리

- 모델/코드 버전을 변경하면 성능 차이를 바로 확인 가능하다

예시 코드: LLM-as-a-Judge 평가 기본 구조 (LangChain v1.0)

```
python

from langsmith import Client
from langchain_openai import ChatOpenAI
from langchain.evaluation import evaluate
from langchain.evaluation import LangChainStringEvaluator

client = Client()

llm = ChatOpenAI(model="gpt-4o-mini", temperature=0)

qa_evaluator = LangChainStringEvaluator(
    "qa",
    prepare_data=lambda run, example: {
        "input": example.inputs["question"],
        "prediction": run.outputs["answer"],
        "reference": example.outputs["answer"]
    }
)

experiment_results = evaluate(
    client=client,
    dataset_name="RAG_EVAL_DATASET",
    evaluators=[qa_evaluator],
    run_evaluators=[qa_evaluator],
)
```

비교 평가 결과 확인

Personal > Datasets & Experiments > RAG_EVAL_DATASET > RAG_EVAL-c65ebd2a

Add resource tags DEVELOPER

RAG_EVAL-c65ebd2a

Compact Full Diff Default Group by Display + Compare

Inputs	Reference Outputs	Outputs	Correctnes...	Latency	Completed	Tokens	Cost
			0.00 AVG	4.289 P50		358.00 T	0.0002 T
대한민국의 수도는 어디인가? #1538 →	서울이다.	대한민국의 수도는 서울입니다.	0.00	0.73s	COMPLETED 1	23	<\$0.01
GPT는 무엇인가? #67bd →	OpenAI가 개발한 언어 모델이다.	GPT(Generative Pre-trained Transformer)	0.00	7.84s	COMPLETED 1	335	<\$0.01

LLM-as-a-Judge 평가 결과 확인

Personal > Datasets & Experiments > RAG_EVAL_DATASET > LLM_JUDGE_EVAL-8e532c9b


Add resource tags DEVELOPER

LLM_JUDGE_EVAL-8e532c9b

Compact Full Diff Default Group by Display + Compare

Inputs	Reference Outputs	Outputs	Llm_judge...	Latency	Completed	Tokens	Cost
			0.75 AVG	3.481 P50		336.00 T	0.0002 T
대한민국의 수도는 어디인가? #1538 →	서울이다.	대한민국의 수도는 서울입니다.	1.00	1.19s	COMPLETED 1	23	<\$0.01
GPT는 무엇인가? #67bd →	OpenAI가 개발한 언어 모델이다.	GPT(Generative Pre-trained Transformer)	0.50	5.77s	COMPLETED 1	313	<\$0.01

대시보드 시각화



LangSmith Criteria 평가 기준 표 [구버전]

기준	설명
conciseness	답변이 간결하고 군더더기 없이 간단한지 평가한다.
relevance	답변이 질문과 관련이 있는지 평가한다.
correctness	답변이 사실적으로 옳은지 평가한다.
coherence	답변의 흐름이 자연스럽고 일관성이 있는지 평가한다.
harmfulness	답변이 해롭거나 위험한 내용을 포함하는지 평가한다.
maliciousness	답변이 악의적이거나 악의적인 의도가 있는지 평가한다.
helpfulness	답변이 사용자에게 실질적으로 도움이 되는지 평가한다.
controversiality	답변이 논란이나 분쟁을 일으킬 가능성이 있는지 평가한다.
misogyny	답변에 여성 비하적 또는 차별적 표현이 있는지 평가한다.
criminality	답변이 범죄를 조장하거나 불법적 행동을 유도하는지 평가한다.



정리

LangSmith 평가란

LLM의 응답 품질을 자동으로 판단하여 개발·운영 효율을 높이는 시스템이다.

- Dataset 기반
- LLM-as-a-judge 방식
- 프롬프트·모델·RAG 성능 비교
- 대시보드에서 시각적 모니터링
- 대규모 자동 평가 가능

RAG, QA, Agent 품질 개선에 매우 강력한 도구이다.





감사합니다